

Tesla T4 : миним. нагрузка 0.25.

FP32 - 4 бит

FLOPS

B-бит S-критерий.

$$\text{Conv } 2B \times W_0 \times C_0 \times L_i \times K^2 : (2352 + 6400 + 2304 + 1024 + 4608 + 1024) B S^2 = 17712 B S^2$$

$$\text{GAP: } 512 B (S/16)^2 = 2 B S^2$$

$$\text{Linear: } (2 \cdot 512 \cdot 256 + 256 + 2 \cdot 256 \cdot 100 + 100) B = 313700 B$$
$$17714 B S^2 + 313700 B$$

Параметры

$$N_{\text{conv}} = 4704 + 51200 + 73728 + 32768 + 589824 + 131072 = 883296$$

$$N_{\text{lin}} = 131328 + 257000 = 157025$$

$$N = 1040324$$

$$4161296 + 68 B S^2 \text{ бит}$$

Оценки записки

$$\text{Conv } 37 B S^2 + 883296$$

$$\text{ReLU } 42 B S^2$$

$$\text{Pool } 14 B S^2$$

$$\text{GAP: } 2 B S^2 + 512 B$$

$$\text{сумма } 1636 B + 157028$$

$$4 (95 B S^2 + 2148 B + 1040324) \text{ бит}$$

Время

t_0 - расход энергии

P - FLOP/s

W - байт/с

$$T = t_0 + \max(F/P ; D/W)$$

Энергия

средняя мощность

$$E = P \cdot T$$

получено на ТЧ элемент матрицы 3,641 нс.

$$t_0 = 5,337 \cdot 10^{-4} \text{ с}$$

$$P = 3,282 \cdot 10^{12} \text{ FLOP/s}$$

$$W = 8,216 \cdot 10^{10} \text{ байт/с}$$

$$P = 95,49 \text{ Вт}$$

или (J, B) (496,256) и (512,256) ООМ